


Relatório de Manutenção Preditiva V3

Modelagem e Análise de Falhas em Ativos

Este relatório apresenta uma análise detalhada da performance do modelo de Machine Learning treinado para prever falhas em máquinas. A metodologia baseia-se no processamento de sensores (temperatura, vibração, pressão) e histórico de manutenção. Neste relatório, de 2000 casos apresentados no dataset foram analisados 600 referentes ao conjunto de testes.



1. Performance do Modelo e Matriz de Confusão

O modelo alcançou uma acurácia de 100% no conjunto de testes. Abaixo, a representação numérica da Matriz de Confusão para os 600 dados de teste:



2. Importância das Variáveis (Feature Importance)

Principais fatores que influenciam a predição de falhas:



3. Análise de Diagnóstico

Observou-se que máquinas que falham apresentam uma média significativamente superior de dias desde a última manutenção (superior a 100 dias) em comparação às que operam normalmente.

4. Passos Recomendados

- **1. Monitoramento Contínuo de Temperatura e Vibração**

Priorizar alertas em tempo real para os dois sensores de maior poder preditivo, com thresholds definidos por faixa operacional do ativo.

- **2. Gatilhos Automáticos de Manutenção**

Implementar regras automáticas que disparem ordens de serviço quando o intervalo sem revisão ultrapassar 90 dias ou os sensores excederem limites críticos.

- **3. Inspeção Prioritária de Correias**

Dado que a falha de correia representa 11% do impacto preditivo, estabelecer protocolo de inspeção visual mensal para este componente.

- **4. Expansão do Dataset e Re-treinamento**

Alimentar o modelo continuamente com novos registros operacionais para manter e aprimorar a acurácia preditiva ao longo do tempo.